

Selezione del modello LLM locale

Esperimenti di validation

1 Selezione del modello LLM locale

Sono confrontate tre famiglie e tre impostazioni sugli stessi 88 circuiti di validation. La scelta riguarda il modello locale con RAG. Il test resta separato e non viene aperto da questa procedura.

1.1 Hardware, dati e misure

Il PC usa AMD Ryzen 5 5600G, 16 GB di RAM e Radeon RX 6750 XT con 12 GB di VRAM. WSL ha un limite di 10 GB di RAM e swap separato. I pesi sono sul disco D. L'ambiente MQT conserva Python 3.12 e uv.lock; llama.cpp b10930 usa Vulkan e carica un modello alla volta.

Si recuperano cinque esempi dal solo train. La distanza è Manhattan su 49 caratteristiche, con log1p e divisori stimati sul train. Circuiti completi, catalogo, maschera ed evidenze sono conservati. Il grafo completo di connettività è scritto con una regola esatta che permette di ricostruire tutti gli archi nello stesso ordine. Nessun prompt viene troncato per farlo entrare nel contesto.

Il monitor conserva campioni di RAM, VRAM e temperatura. Le pause automatiche del solo processo di inferenza sono incluse nei tempi. I limiti operativi sono prudenziali e non identificano la causa dello spegnimento iniziale del PC. La potenza del sensore ASIC non è l'energia consumata dall'intero computer.

Modello	Pesi	Contesto	Cache KV
qwen	Q8_0	60000	q8_0
phi	Q8_0	60000	q8_0
gemma	Q8_0	60000	q8_0

Gemma E4B ha un numero di parametri totali maggiore del numero di parametri attivi. Revisioni, dimensioni, SHA-256, tokenizer e motivazioni della precisione sono conservati nei manifest e nella configurazione finale.

1.2 Prove tecniche e sviluppo

Le prove tecniche precedono il congelamento e usano il train. I file technical_episodes.csv e server_runs.csv riportano anche configurazioni scartate, interruzioni e caricamenti arrestati prima di una risposta. I registri esplorativi precedenti sono conservati in technical/ e incidents/.

Il riepilogo degli episodi tecnici registrati contiene 68 episodi: 20 failure, 1 interrupted_or_pending, 33 success, 14 timeout. Questi conteggi non fanno parte dei risultati della validation.

1.3 Impostazioni e criteri

Le impostazioni confrontate sono: prompt base a temperatura 0; prompt base a temperatura 0,7; prompt con controlli espliciti a temperatura 0. Il ragionamento esteso è disabilitato. La prima risposta valida è definitiva. Si ammettono al massimo tre chiamate per correggere risposte non conformi; trasporto, interruzioni e correzioni sono registrati separatamente.

Parametro	Valore
max_tokens	4096
top_p	0.95
top_k	40
min_p	0.0
seed	20260913
repeat_penalty	1.0
presence_penalty	0.0
frequency_penalty	0.0
mirostat	0
typical_p	1.0
Timeout per chiamata [s]	3600

$$R(c) = F_{\text{oracle}}(c) - F_{\text{scelta}}(c).$$

La fedeltà di una coppia è la mediana dei seed 0, 1 e 2, solo se tutti e tre riescono. L’oracle richiede l’intera matrice compatibile riuscita. I regret mancanti restano mancanti. I punteggi e i tempi Qiskit sono riutilizzati da risultati precedenti. I nuovi tempi delle chiamate LLM sono misurati.

Prima di leggere gli score sono sigillate tutte le decisioni. La selezione privilegia le scelte valide e compilabili; a parità usa la mediana del regret sullo stesso insieme di circuiti riusciti e valutabili. Seguono validità JSON iniziale, chiamate e costi misurati. Il circuito è l’unità statistica: seed e tentativi non aumentano la numerosità.

1.4 Risultati

Prova	Riuscite/88	Regret n	Mediana regret	Valide alla prima
gemma/p0_t0	88	18	0.006643	88
gemma/p0_t07	87	18	0.001615	87
gemma/p1_t0	88	18	0.006643	88
phi/p0_t0	88	18	0.004031	88
phi/p0_t07	87	18	0.001962	87
phi/p1_t0	88	18	0.004031	88
qwen/p0_t0	88	18	0.003378	88
qwen/p0_t07	88	18	0.0019	88
qwen/p1_t0	87	18	0.005555	87

La configurazione selezionata è **qwen/p0_t07**. I passaggi della scelta, con valori e denominatori, sono conservati in selection.json. Questa selezione non dimostra una superiorità generale del modello.




Figura 1: Regret assoluto. La numerosità indica i casi misurabili; i valori assenti non sono sostituiti con zero.




Figura 2: Tempo delle chiamate [min]. La numerosità indica i casi misurabili; i valori assenti non sono sostituiti con zero.




Figura 3: Token di uscita, tutte le chiamate. La numerosità indica i casi misurabili; i valori assenti non sono sostituiti con zero.




Figura 4: Picco RAM campionato del processo [GiB]. La numerosità indica i casi misurabili; i valori assenti non sono sostituiti con zero.




Figura 5: Picco VRAM campionato del processo [GiB]. La numerosità indica i casi misurabili; i valori assenti non sono sostituiti con zero.




Figura 6: Affidabilità e correzioni sugli stessi 88 circuiti per ogni impostazione.




Figura 7: Categorie degli errori. I registri distinguono trasporto, contesto, risposta e compilazione.




Figura 8: Lunghezza del prompt, tempi e fallimenti. Le impostazioni dello stesso circuito non sono repliche indipendenti.




Figura 9: Affidabilità per famiglia di circuito. I regret e gli altri indicatori dei gruppi sono esportati in groups.csv.




Figura 10: Affidabilità per numero di qubit. I regret e gli altri indicatori dei gruppi sono esportati in groups.csv.




Figura 11: Affidabilità per numero di qubit. I regret e gli altri indicatori dei gruppi sono esportati in groups.csv.




Figura 12: Affidabilità per numero di qubit. I regret e gli altri indicatori dei gruppi sono esportati in groups.csv.




Figura 13: Affidabilità per numero di qubit. I regret e gli altri indicatori dei gruppi sono esportati in groups.csv.

1.5 Incertezza e limiti

Il file `paired_uncertainty.json` confronta il vincitore e le alternative sugli stessi circuiti valutabili. Riporta la mediana delle differenze appaiate di regret e intervalli percentili al 95%, con 2000 ricampionamenti di circuiti e seed 20260913. Con meno di due circuiti non si calcola l'intervallo. Questi intervalli sono descrittivi e non correggono la selezione tra più impostazioni.

Cache, ordine delle richieste, pause e altri programmi del PC influenzano i tempi. I massimi campionati possono perdere picchi istantanei. I valori mancanti rimangono espliciti. Le prove tecniche e le configurazioni scartate sono conservate separatamente.

La validation locale non richiede qcompile completo. Sul test restano previsti modello senza RAG, MQT, modello di frontiera e riferimenti Qiskit, dopo i controlli richiesti dal protocollo. Questo documento non contiene risultati del test.

1.6 Dati e fonti

Per rigenerare il documento usare la procedura nel README di `llm_selection`. `episodes.csv`, `trials.csv`, `groups.csv` e i registri JSON/JSONL permettono nuove analisi senza trascrivere i risultati.

qwen: Success rate 100% on 5 train circuits and less usage of tokens. Batch 512, micro-batch 128, livelli GPU all.

phi: Success rate 100% on 5 train circuits and less usage of tokens. Batch 512, micro-batch 128, livelli GPU all.

gemma: Success rate 100% on 5 train circuits and less usage of tokens. Batch 512, micro-batch 128, livelli GPU all.

qwen: <https://huggingface.co/Qwen/Qwen3.5-4B>.

Pesi effettivi: https://huggingface.co/unsloth/Qwen3.5-4B-GGUF/resolve/e87f176479d0855a907a4127Qwen3.5-4B-Q8_0.gguf.

SHA-256: 10cc391b403021dd11c614679d2fd92f611c3681d29e29651b717316965d61e1.

phi: <https://huggingface.co/microsoft/Phi-4-mini-instruct>.

Pesi effettivi: https://huggingface.co/unsloth/Phi-4-mini-instruct-GGUF/resolve/78eb92a46fc37e6Phi-4-mini-instruct.Q8_0.gguf.

SHA-256: 26188c6050d525376a88b04514c236c5e28a36730f1e936f2a00314212b7ba42.

gemma: <https://huggingface.co/google/gemma-4-E4B-it>.

Pesi effettivi: https://huggingface.co/ggml-org/gemma-4-E4B-it-GGUF/resolve/b8093469224f83f5c38gemma-4-E4B-it-Q8_0.gguf.

SHA-256: 34be82b17b4942d389b9b527170c4b058027abdd32531fda063d3d97dd8ce80a.

<https://github.com/ggml-org/llama.cpp/blob/b10930/tools/server/README.md>.