

VALUTAZIONE DEI SISTEMI DI COMPILAZIONE QUANTISTICA

LLM + RAG e MQT Predictor
Confronto su QASMBench

Ulteriore test indipendente

Esecuzioni del 30 settembre 2026 · 50 circuiti · 2 sistemi

1 Risultati principali

Il test usa circuiti provenienti da QASMBench, diversi dal corpus MQT Bench del progetto. Sono stati selezionati 30 circuiti piccoli, 15 medi e 5 grandi. Questo documento analizza i registri conservati; non avvia nuove compilazioni e non modifica le configurazioni valutate.

Indicatore	LLM + RAG	MQT Predictor
Compilazioni riuscite / circuiti previsti	50/50 (100%)	48/50 (96%)
Score almeno 0,8 / circuiti previsti	41/50 (82%)	43/50 (86%)
Score medio: stessi 48 circuiti	0,8839	0,9168
Tempo totale medio: stessi 48 circuiti	26,76 s	17,94 s
Compilazione interna media: stessi 48	0,95 s	13,50 s

Copertura. LLM + RAG completa tutti i circuiti. MQT Predictor termina entro il limite su 48 circuiti. I due timeout, su `gcm_n13` e `qft_n63`, sono riportati separatamente: non ricevono uno score pari a zero.

Qualità. Nei 48 successi comuni, MQT Predictor ottiene uno score medio maggiore di 0,0329. LLM + RAG ottiene lo score maggiore in 22 casi e MQT in 26; non ci sono parità. Le differenze più ampie a favore di MQT si concentrano in alcuni circuiti medi.

Tempi. La compilazione interna scelta dall'LLM è più rapida in tutti i 48 successi comuni. Il tempo necessario a preparare e ottenere la decisione LLM cambia però il risultato complessivo: MQT è più rapido in 45 di questi 48 casi.

Lettura del confronto. Lo score è una fedeltà *stimata* sui Target sintetici, non una misura su hardware quantistico. Il test confronta i due sistemi completi, con strategie di compilazione diverse. Non permette di attribuire il risultato al solo selettore del dispositivo.

2 Circuiti e impostazioni

La selezione è fissata nel manifest della campagna, prima di queste analisi. È una selezione ragionata, non un campione casuale dell'intera raccolta QASMBench. Non sono state trovate copie identiche byte per byte nel corpus MQT controllato. Questo controllo non esclude equivalenze algoritmiche o la presenza di circuiti simili nell'addestramento originario dell'LLM.

Fascia	Circuiti	Quota	Qubit osservati
Piccoli	30	60%	2–10
Medi	15	30%	11–27
Grandi	5	10%	28, 63, 98, 111, 140

Voce	Impostazione
LLM	Qwen3.5-4B, pesi Q8_0, temperatura 0
Generazione	Seed 20260913; massimo 4096 token in uscita
Altri parametri	top_p 0,95; top_k 40; min_p 0; cache attiva
Contesto	60 000 token richiesti; 60 160 dichiarati dal server
RAG	5 esempi; distanza Manhattan; 49 caratteristiche
Dataset RAG	396 circuiti train distinti; formato del prompt TOON
Decisione	Contratto 4.0.0; al massimo 3 risposte completate
MQT	mqt.predictor 2.4.0; selettore supervisionato + politiche RL
Training set MQT	384 dei 396 campioni previsti; 12 esclusi
Raccolta del Training set	1853/1878 compilazioni riuscite; limiti adattivi 100/300 s
Compilazione del Test	Una per circuito e metodo; limite del processo: 100 s
Semi della compilazione	Qiskit: 0; campionamento MQT: 0
Ambiente	Python 3.12.13; WSL2 x86_64; 12 CPU logiche rilevate

Misura della qualità. Per ciascuna istruzione non di barriera del circuito compilato si usa l'errore registrato nel Target. La metrica riproduce `expected_fidelity` di MQT Predictor 2.4.0

3 Riuscita e soglia di qualità




Figura 1: Tutti i 50 circuiti per sistema. I timeout sono distinti dai successi sotto soglia. La soglia 0,8 riprende il report di riferimento; non è una garanzia di accuratezza fisica.

Fascia	Successi LLM	Successi MQT	$S \geq 0,8$ LLM	$S \geq 0,8$ MQT
Totale	50/50	48/50	41/50	43/50
Piccoli	30/30	30/30	30/30	29/30
Medi	15/15	14/15	11/15	14/15
Grandi	5/5	4/5	0/5	0/5

Nei piccoli circuiti LLM + RAG supera la soglia in tutti i casi. Nei medi, MQT la supera in tutti i 14 casi completati, mentre LLM + RAG la supera in 11 casi su 15. Nessuno dei due sistemi raggiunge 0,8 sui grandi circuiti completati.

I due timeout di MQT Predictor

Il limite di 100 secondi riguarda l'intero processo di compilazione: include avvio, importazioni e selezione del dispositivo. La durata registrata supera leggermente il limite per l'arresto e la raccolta dell'esito.

Circuito	Qubit	Target MQT	S LLM	Totale LLM	Totale MQT
gcm_n13	13	Q56	0,533621	27,60 s	100,17 s
qft_n63	63	H156	0,000076	22,01 s	100,18 s

I Target dei due timeout sono ricavati da `selection.json`, scritto prima della compilazione: Q56 indica Quantinuum H2-56 e H156 IBM Heron 156. La scelta era quindi già avvenuta. Non è disponibile uno score MQT da confrontare. LLM + RAG completa `qft_n63`, ma con uno score molto basso: riuscita tecnica e qualità del risultato restano due misure distinte.

4 Qualità sui 48 successi comuni




Figura 2: A sinistra ogni punto è un circuito: sopra la diagonale prevale LLM + RAG. A destra la distribuzione cumulativa sui medesimi 48 circuiti: a parità di score, una quota più bassa indica meno circuiti con qualità bassa.

Popolazione	Sistema	N	Media	Mediana	Minimo
Successi comuni	LLM + RAG	48	0,8839	0,9438	0,011468
Successi comuni	MQT Predictor	48	0,9168	0,9736	0,003015
Tutti i successi	LLM + RAG	50	0,8592	0,9361	0,000076
Tutti i successi	MQT Predictor	48	0,9168	0,9736	0,003015

La prima coppia di righe è il confronto principale: entrambi gli score esistono per gli stessi circuiti. Le medie su tutti i successi hanno denominatori diversi e servono soltanto a descrivere ciascun sistema.

5 Dove cambiano maggiormente gli score




Figura 3: Differenze sui singoli circuiti. Valori positivi favoriscono LLM + RAG. Gli indici 39 e 47 non hanno una barra: sono i timeout MQT. L’appendice associa gli indici ai nomi.

Circuito	LLM	MQT	Δ	Target L/M
sat_n11	0,7096	0,9607	-0,2511	Q56/Q56
multiplier_n15	0,7112	0,9444	-0,2332	Q56/Q56
qft_n18	0,7720	0,9690	-0,1970	Q56/Q56
dmn_n16	0,8130	0,9463	-0,1333	Q56/Q56
basis_trotter_n4	0,8015	0,7261	+0,0754	Q56/Q56
iswap_n2	0,9991	0,9847	+0,0143	F127/F127
quantumwalks_n2	0,9979	0,9837	+0,0142	F127/F127
vqe_n4	0,9900	0,9774	+0,0126	F127/Q56

La tabella mostra i quattro maggiori scarti in ciascuna direzione, senza selezionare i casi in base alla narrativa. I nomi dei dispositivi sono abbreviati: F127 = IBM Falcon 127, H133/H156 = IBM Heron 133/156, Q56 = Quantinuum H2-56.

Il maggiore vantaggio MQT compare su `sat_n11`: lo scarto è 0,2511. Il maggiore vantaggio LLM + RAG compare su `basis_trotter_n4`: 0,0754.

La sola scelta dello stesso dispositivo non rende uguali i sistemi. LLM + RAG sceglie anche una configurazione Qiskit dal catalogo; MQT usa una politica RL per costruire la sequenza dei passi. Differenze di dispositivo e di compilazione agiscono insieme. Questi dati non isolano una causa unica del vantaggio osservato.

6 Costo delle decisioni LLM e correzioni

Misura	Totale	Media per circuito	Mediana
Token in ingresso	903 142	18 063	12 067
Token in uscita	12 529	251	158
Token complessivi	915 671	18 313	12 231
Chiamate LLM	78,00	1,56	1,00
Chiamate aggiuntive	28,00	0,56	0,00
Tempo RAG (s)	179,37	3,59	3,63
Tempo risposte LLM (s)	1 014,57	20,29	19,65




Figura 4: Le correzioni aumentano il numero di richieste e il volume di token. Le colonne di destra sono medie su 35, 2 e 13 circuiti, rispettivamente. Non misurano l'effetto causale delle correzioni sulla qualità.

7 Scelte dei sistemi e limiti del confronto

Dispositivo	LLM (50 successi)	MQT (48 successi)	MQT timeout
IBM Falcon 27	0	0	0
IBM Falcon 127	12	8	0
IBM Heron 133	0	4	0
IBM Heron 156	10	1	1
Quantinuum H2-56	28	35	1

LLM + RAG sceglie 24 volte `o2_default_default`, 24 volte `o3_default_default` e 2 volte `o2_dense_sabre`. MQT non sceglie una di queste configurazioni: esegue i passi della politica RL. Il suo selettore conserva quattro classi di dispositivo (Falcon 127, Heron 133, Heron 156 e H2-56). Falcon 27 è disponibile nel catalogo, ma non è una classe appresa da questo selettore. Le frequenze riflettono anche capacità e compatibilità dei dispositivi con i circuiti.

Ambito della conclusione. MQT ottiene una qualità media maggiore sui 48 circuiti confrontabili; LLM + RAG offre copertura completa entro il limite impostato. La rapidità della compilazione Qiskit non basta a rendere più rapido l'intero sistema LLM. Sono tre risultati distinti: qualità, riuscita e tempo.

Vincoli dei modelli. Il confronto riguarda gli artefatti realmente usati. Il Training set del selettore MQT comprende 384 campioni, non tutti i 396 previsti. La raccolta che lo ha prodotto ha 1853 compilazioni riuscite su 1878 e ha usato limiti adattivi di 100/300 secondi. Questi limiti di addestramento sono diversi dai 100 secondi del Test. Il documento non estende i risultati a un selettore ritrainato su dati diversi.

8 Appendice: risultati per circuito

A = LLM + RAG; B = MQT Predictor. S è lo score; t il tempo totale in secondi, comprensivo della scelta. P/M/G indicano piccolo/medio/grande. TO indica un timeout: il tempo dell'arresto è osservato, lo score è assente. Il prefisso `qasmbench_` è omissso dai nomi.

N.	Circuito	Qubit	F.	S_A	S_B	t_A	t_B	Ch.
1	deutsch_n2	2	P	0,99931	0,99330	22,4	14,8	1
2	iswap_n2	2	P	0,99907	0,98474	22,8	14,3	1
3	quantumwalks_n2	2	P	0,99793	0,98372	22,6	12,1	1
4	grover_n2	2	P	0,99907	0,98751	29,5	14,0	3 *
5	dnn_n2	2	P	0,99658	0,99491	27,2	15,8	2
6	qaoa_n3	3	P	0,98904	0,98271	23,3	16,7	1
7	toffoli_n3	3	P	0,98933	0,98995	29,3	14,5	3 *
8	fredkin_n3	3	P	0,98524	0,98505	22,8	14,7	1
9	wstate_n3	3	P	0,98799	0,99139	22,7	14,3	1
10	basis_change_n3	3	P	0,98669	0,97700	23,4	17,5	1
11	qrng_n4	4	P	0,99923	0,99651	24,1	14,5	1
12	cat_state_n4	4	P	0,99106	0,98806	23,0	14,0	1
13	adder_n10	10	P	0,90552	0,94882	27,1	26,1	1
14	adder_n4	4	P	0,97995	0,98985	22,8	14,5	1
15	hs4_n4	4	P	0,99394	0,98629	29,3	16,0	3 *
16	bell_n4	4	P	0,99179	0,99163	27,0	16,3	2
17	qft_n4	4	P	0,98123	0,99312	29,3	14,3	3 *
18	variational_n4	4	P	0,98135	0,98806	31,4	14,5	3 *
19	vqe_n4	4	P	0,98999	0,97744	29,8	14,4	3 *
20	sat_n7	7	P	0,91985	0,96072	30,3	15,6	1
21	basis_trotter_n4	4	P	0,80151	0,72615	30,2	54,7	3 *
22	lpn_n5	5	P	0,98916	0,98821	23,5	15,7	1
23	qec_en_n5	5	P	0,97659	0,97408	24,8	14,4	1
24	pea_n5	5	P	0,97956	0,98970	30,0	17,8	3 *
25	simon_n6	6	P	0,97171	0,98230	24,8	14,4	1

Ch. indica il numero di chiamate LLM. L'asterisco segnala una decisione accettata con fatti non completamente verificati. Gli score sono visualizzati con cinque decimali: confronti, soglie e differenze sono calcolati dai dieci decimali conservati nei registri, prima di questa formattazione.

I file `dati/circuiti.csv` e `dati/coppie.csv` riportano anche tempi interni e di processo, dispositivi, configurazioni, token, correzioni, log-score, stati e impronte dei circuiti. I dati mancanti restano vuoti, senza sostituzione con zeri.

9 Appendice: risultati per circuito (continua)

A = LLM + RAG; B = MQT Predictor. S è lo score; t il tempo totale in secondi, comprensivo della scelta. P/M/G indicano piccolo/medio/grande. TO indica un timeout: il tempo dell'arresto è osservato, lo score è assente. Il prefisso `qasmbench_` è omissso dai nomi.

N.	Circuito	Qubit	F.	S_A	S_B	t_A	t_B	Ch.
26	qaoa_n6	6	P	0,91851	0,99014	24,3	17,2	1
27	hhl_n7	7	P	0,89586	0,94272	25,3	21,1	1
28	dnn_n8	8	P	0,90167	0,97276	25,3	18,8	1
29	qpe_n9	9	P	0,94993	0,98327	33,7	16,4	3 *
30	ising_n10	10	P	0,91571	0,97305	30,4	18,8	3 *
31	sat_n11	11	M	0,70958	0,96072	27,7	24,4	1
32	multiply_n13	13	M	0,84679	0,96320	30,0	15,1	3 *
33	bv_n14	14	M	0,95933	0,95196	26,4	18,3	1
34	multiplier_n15	15	M	0,71118	0,94442	26,3	24,3	1
35	dnn_n16	16	M	0,81300	0,94626	60,2	16,4	3 *
36	qec9xz_n17	17	M	0,93769	0,93275	25,2	14,9	1
37	qft_n18	18	M	0,77199	0,96897	25,6	19,6	1
38	bigadder_n18	18	M	0,82127	0,87811	27,6	19,7	1
39	gcm_n13	13	M	0,53362	TO	27,6	100,2	1
40	qram_n20	20	M	0,82485	0,89730	25,5	19,0	1
41	cat_state_n22	22	M	0,93449	0,93393	25,1	12,5	1
42	ghz_state_n23	23	M	0,93155	0,92533	24,9	15,1	1
43	swap_test_n25	25	M	0,87169	0,94754	25,2	33,8	1
44	ising_n26	26	M	0,92303	0,93441	30,5	14,6	3 *
45	wstate_n27	27	M	0,88191	0,88077	25,2	22,0	1
46	adder_n28	28	G	0,72849	0,79888	24,4	23,0	1
47	qft_n63	63	G	0,00008	TO	22,0	100,2	1
48	ising_n98	98	G	0,52219	0,65273	21,9	23,0	1
49	qugan_n111	111	G	0,01147	0,00301	26,5	13,8	1
50	bv_n140	140	G	0,26202	0,27250	14,4	13,5	1

Ch. indica il numero di chiamate LLM. L'asterisco segnala una decisione accettata con fatti non completamente verificati. Gli score sono visualizzati con cinque decimali: confronti, soglie e differenze sono calcolati dai dieci decimali conservati nei registri, prima di questa formattazione.

I file `dati/circuiti.csv` e `dati/coppie.csv` riportano anche tempi interni e di processo, dispositivi, configurazioni, token, correzioni, log-score, stati e impronte dei circuiti. I dati mancanti restano vuoti, senza sostituzione con zeri.